

Modelo Preditivo Copa 2026

Dendê Softhouse – Equipe Lauro

Autores: Carlos Henrique de Souza Santana Santiago
Gustavo Bezerra Nonato
Hudnei Sued Passos Santana
João Guilherme Gonçalves Pinheiro
Áleffy De Almeida Figueiredo Santos

Agenda

Nesta apresentação, veremos um modelo preditivo para o campeão da Copa do Mundo de 2026. Utilizando técnicas de Mineração de Dados para extrair padrões ocultos e oferecer um sistema com alta precisão e baixo custo de processamento.

1. A Dendê Softhouse

O nosso desafio e modelo de negócio

2. Exploração e Pré-processamento:

Lendo, limpando e preparando os dados brutos

3. Escolha das Características:

Definindo o que realmente importa para a IA


4. Treino e Avaliação:

Calibrando o sistema e aplicando a prova final

5. O Veredicto:

A previsão oficial do Campeão de 2026

Será possível prever o campeão
da Copa do Mundo?




Lendo e preparando os dados



Importando bibliotecas

pandas
numpy
scikit-learn
matplotlib

Lendo *train.csv* e *test.csv* com
pandas.



Lendo e preparando os dados



Temos 25 colunas

3 categóricas e
22 numéricas



Lendo e preparando os dados



Temos 25 colunas

```
team_name | country_code | confederation
```

3 categóricas e
22 numéricas

```
fifa_points | win_rate_last_year |  
goals_scored_avg | shots_per_game |  
market_value_million_eur
```

Lendo e preparando os dados



Remoção de nulos



```
1 X_train.fillna(0, inplace=True)
2 X_test_final.fillna(0, inplace=True)
```

Remoção de duplicados



Lendo e preparando os dados



Codificação de Dados Categóricos



```
1 df_combined = pd.get_dummies(df_combined, columns=['confederation'])
```

Lendo e preparando os dados




Transformação/Padronização da Escala de Dados Numéricos




```
1 from sklearn.ensemble import RandomForestClassifier
2     modelo = RandomForestClassifier(n_estimators=100, random_state=42)
3     print("Algoritmo Random Forest instanciado.")
```


Lendo e preparando os dados



Time, distância
de viagem e
clima local.



Posição no
Ranking da FIFA e
Valor de Mercado
do elenco.



Média de gols,
posse de bola e
precisão de
passes.




Nota média dos
jogadores, quantidade
de "craques" e
experiência do
técnico.

Escolhendo as características



Ficamos com todas as colunas numéricas, pois algoritmos não entendem o que é futebol.




Escolhendo as características



Ficamos com todas as colunas numéricas, pois algoritmos não entendem o que é futebol.

Passamos de 25 para 28 colunas.



Configurando Hiperparâmetros



Configuração	Nº de Especialistas	Tempo de Resposta	Acurácia (Acerto)
1. Rápida	50 Árvores	0.08 segundos	59.00%
2. A Escolhida	100 Árvores	0.17 segundos	60.50% (Melhor F1-Score)
3. Pesada	200 Árvores	0.32 segundos	59.50% (Queda de precisão!)

A nota de acerto ficou baixa, em 59%.
Rápidos, mas erraram muito.

Configurando Hiperparâmetros



Configuração	Nº de Especialistas	Tempo de Resposta	Acurácia (Acerto)
1. Rápida	50 Árvores	0.08 segundos	59.00%
2. A Escolhida	100 Árvores	0.17 segundos	60.50% (Melhor F1-Score)
3. Pesada	200 Árvores	0.32 segundos	59.50% (Queda de precisão!)

Gastou o dobro do tempo processando (0.32 segundos)
e a precisão caiu para 59,50%.

Configurando Hiperparâmetros



Configuração	Nº de Especialistas	Tempo de Resposta	Acurácia (Acerto)
1. Rápida	50 Árvores	0.08 segundos	59.00%
2. A Escolhida	100 Árvores	0.17 segundos	60.50% (Melhor F1-Score)
3. Pesada	200 Árvores	0.32 segundos	59.50% (Queda de precisão!)

Nós encontramos o equilíbrio exato entre custo de servidor e inteligência preditiva para a Dendê Softhouse.

Treino e teste



80/20



```
1 X_train, X_val, y_train, y_val = train_test_split  
  (X, y, test_size=0.2, random_state=42)
```

Separamos 20% da base
para provar que o
algoritmo realmente
aprendeu a identificar o
padrão de um time
vencedor.

Treino e teste



Terminal

```
MÉTRICAS DE AVALIAÇÃO DO MODELO
```

```
=====
```

```
Acurácia: 60.50%
```

```
Matriz de Confusão:
```

```
[[67 25]
```

```
[54 54]]
```

60.50% é a taxa geral de acerto do nosso algoritmo em todos os cenários.

Treino e teste



Terminal

Relatório de Classificação Completo:


	precision	recall	f1-score	support
0	0.55	0.73	0.63	92
1	0.68	0.50	0.58	108
accuracy			0.60	200
macro avg	0.62	0.61	0.60	200
weighted avg	0.62	0.60	0.60	200

Modelo pronto para gerar as previsões oficiais.

F1-Measure: 0.58 > O modelo sabe prever vitórias reais sem disparar **falsos favoritos**.



E o campeão será...

unex



E o campeão será...

unex



Referências



- DANILO S. C. Metodologia de Modelos Preditivos. [S. I.], [20--]. Disponível em: https://danilosc.com/teaching/datamining/met_modelos_preditivos/#/5/0/0. Acesso em: 30 mai. 2026.
- IBM. Análise Preditiva. IBM Think, [20--]. Disponível em: <https://www.ibm.com/br-pt/think/topics/predictive-analytics>. Acesso em: 29 mai. 2026.
- SAS. 9 passos para uma modelagem preditiva eficaz. SAS Blogs, 23 abr. 2020. Disponível em: <https://blogs.sas.com/content/sasla/2020/04/23/9-passos-para-umamodelagem-preditiva-eficaz/>. Acesso em: 28 mai. 2026.
- ZOHO. Benefícios do modelo preditivo. Zoho Blog, [20--]. Disponível em: <https://www.zoho.com/blog/pt-br/analytics/beneficios-do-modelopreditivo.html>. Acesso em: 1 jun. 2026.